1ª Entrega: Organização do dataset e planejamento dos experimentos

Aplicações em Sistemas Inteligentes · Atividade Prática 2 · 20/10/2026
Nycaio Bezerra (2220230) · Pedro Henrique (2420509)

1. Dataset

Base: *A large scale 12-lead electrocardiogram database for arrhythmia study* (PhysioNet, v1.0.0).

- 45.152 ECGs de 12 derivações, 10 s, 500 Hz, no formato WFDB (`.hea` + `.mat`), 5,3 GB.
- Cada registro pertence a um paciente diferente, então a divisão por registro já é uma **divisão por paciente**, sem vazamento entre treino, validação e teste.
- Rótulos: códigos SNOMED-CT na linha `#Dx` do cabeçalho. A base usa 94 códigos diferentes e metade dos exames tem mais de um diagnóstico (até 12).

Definição das classes (ritmo cardíaco)

Como cada exame pode ter vários diagnósticos, e o treino exige **uma classe por imagem**, usamos como rótulo apenas o **ritmo cardíaco** (o coração só tem um ritmo por vez). Cada um dos 9 ritmos presentes na base virou uma classe:

Classe	Ritmo	Imagens	%	SB ÷ classe
SB	Bradicardia sinusal	15.793	36,5%	1×
AF	Flutter atrial	7.964	18,4%	2,0×
SR	Ritmo sinusal (normal)	7.872	18,2%	2,0×
ST	Taquicardia sinusal	7.118	16,4%	2,2×
SA	Irregularidade sinusal	1.810	4,2%	8,7×
AFIB	Fibrilação atrial	1.780	4,1%	8,9×
SVT	Taquicardia supraventricular	660	1,5%	24×
AT	Taquicardia atrial	250	0,6%	63×
AVRT	Taquicardia por reentrada atrioventricular	24	0,06%	658×
Total		**43.271**	100%	

Exames descartados (1.881): 949 sem nenhum ritmo identificado, 838 com ritmos conflitantes (ex.: fibrilação + ritmo sinusal) e 94 com sinal vazio/NaN ou cabeçalho ilegível. Nos 321 exames com dois ritmos parecidos, prevaleceu o diagnóstico mais específico (ex.: SR + SA → SA; ST + AT → AT).

Conjunto utilizado

- **Base completa, sem subconjunto:** todos os 43.271 ECGs com ritmo válido. A conversão para PNG gerou 1,8 GB de imagens, volume viável de treinar no Google Colab.
- A base é **fortemente desbalanceada**: as 4 maiores classes (SB, AF, SR e ST) somam 89,5% das imagens, enquanto SVT, AT e AVRT somam só 2,2%. SB tem 658 vezes mais exames que AVRT.

Divisão estratificada 70/15/15 (seed = 42, igual para todos os integrantes)

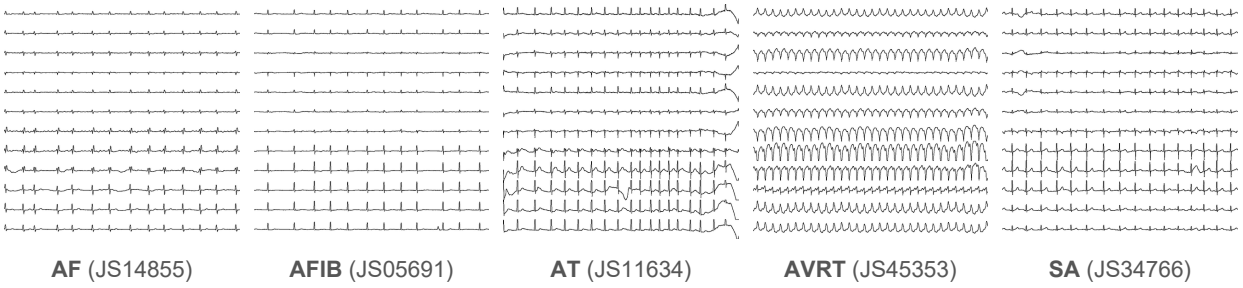
Classe	Treino	Validação	Teste	Total
AF	5.575	1.195	1.194	7.964
AFIB	1.246	267	267	1.780
AT	176	37	37	250
AVRT	17	3	4	24
SA	1.268	270	272	1.810
SB	11.058	2.372	2.363	15.793
SR	5.510	1.183	1.179	7.872
ST	4.987	1.064	1.067	7.118
SVT	462	99	99	660
Total	**30.299**	**6.490**	**6.482**	**43.271**

A lista exata de registros de cada conjunto fica em `dataset_ecg/divisao.csv`.

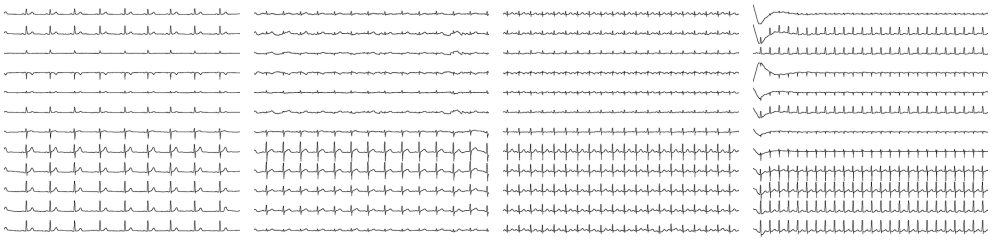
Conversão de WFDB para imagem

- Leitura com `wfdb.rdrecord()`: sinal em mV (5000 amostras × 12 derivações).
- Filtro passa-banda Butterworth de 0,5 a 40 Hz: remove a oscilação da linha de base e o ruído de alta frequência.
- As 12 derivações (I, II, III, aVR, aVL, aVF, V1–V6) são empilhadas verticalmente, mostrando os 10 s completos em cada uma, com a **mesma escala em mV** para todas (preserva a amplitude).
- PNG de 512×512, traço preto em fundo branco (redimensionado para 224×224 no treino).

Exemplos de imagens geradas (uma por classe):



AF (JS14855) **AFIB** (JS05691) **AT** (JS11634) **AVRT** (JS45353) **SA** (JS34766)



SB (JS29194) **SR** (JS06547) **ST** (JS41892) **SVT** (JS10209)

2. Estratégias de Data Augmentation

Definidas no arquivo `transformacoes.py`, que é o mesmo para toda a equipe. O augmentation é aplicado **somente no treino**. Validação e teste usam a configuração A.

Transformações proibidas para ECG

- **Flip horizontal:** inverte o tempo (a onda P passaria a vir depois do QRS).
- **Flip vertical:** inverte a polaridade das ondas, o que muda o diagnóstico.
- **Rotações e recortes grandes:** cortam batimentos e distorcem os intervalos RR, que são a principal informação para classificar o ritmo.

Configuração	Transformações
A – Sem augmentation	Resize 224×224 + ToTensor + Normalize (média e desvio do ImageNet)
B – Leve	Translação ±2% + brilho ±10%
C – Moderado	Translação ±4% + escala 0,95–1,05 + brilho ±20% + contraste ±20%
D – Pesado	Rotação ±3° + translação ±6% + escala 0,90–1,10 + brilho/contraste ±30% + Gaussian blur (kernel 3, sigma 0,1–1,0, p = 0,3) + Random Erasing (1–4% da área, p = 0,3)

Nas transformações geométricas, o espaço novo é preenchido com branco (fill = 255). O Random Erasing também usa branco e simula pequenos trechos com perda de sinal.

Hiperparâmetros fixos (todos os experimentos)

Parâmetro	Valor
Batch size	32
Otimizador	Adam, learning rate = 0,001
Épocas (máximo)	100
Early Stopping	Paciência 5, monitorando a val loss e restaurando o melhor modelo
Transfer Learning	Pesos do ImageNet, backbone congelado, treino apenas da camada de saída
Seed	42

Tratamento do desbalanceamento

Optamos por manter a base completa, sem descartar exames (undersampling) nem duplicar imagens. O primeiro treino (seção 4) foi feito sem correção, como referência. A estratégia planejada para todos os experimentos é **pesos por classe na função de perda** (`CrossEntropyLoss(weight=...)`, peso inversamente proporcional à frequência da classe no treino), para que errar uma classe rara custe mais. Na avaliação, além da acurácia, serão analisados o recall por classe e o F1 macro, já que a acurácia é dominada pela classe SB.

3. Distribuição das arquiteturas

Cada integrante treina 3 arquiteturas nas 4 configurações (12 treinamentos por pessoa, 24 no total), cobrindo 5 famílias (EfficientNet, ResNet, DenseNet, VGG e MobileNet).

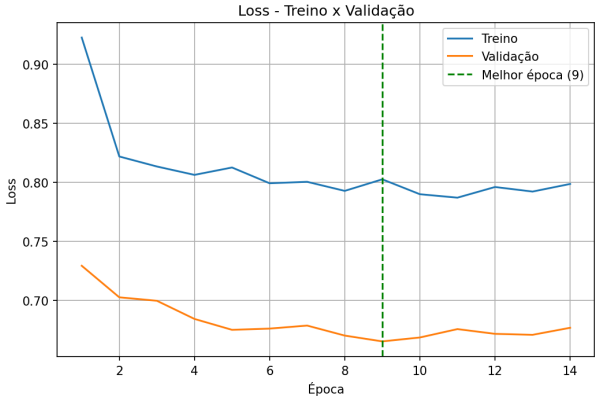
Integrante	Matrícula	Arquitetura 1	Arquitetura 2	Arquitetura 3
Nycaio Bezerra	2220230	EfficientNet-B2	ResNet50	DenseNet121
Pedro Henrique	2420509	VGG16	MobileNetV3-Large	ResNet18

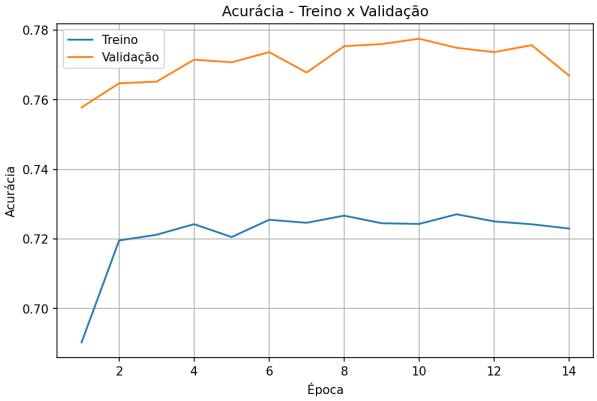
4. Resultados parciais: EfficientNet-B2, configuração A (sem augmentation)

Primeiro treinamento concluído no Google Colab, sem correção de desbalanceamento.

Métrica	Treino	Validação	Teste
Acurácia	72,45%	**77,60%**	77,12%
Loss	0,803	**0,665**	—
F1 macro	—	0,446	0,446
F1 ponderado	—	0,749	0,744

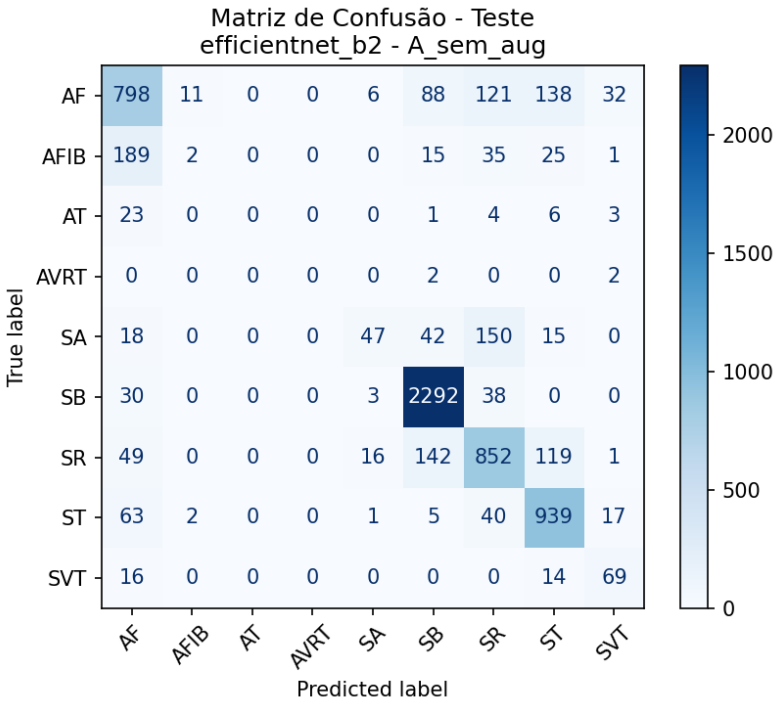
Melhor época: **9** · Épocas executadas: **14** (Early Stopping após 5 épocas sem melhora) · Tempo de treinamento: **44,3 min**





Desempenho por classe (teste)

Classe	Imagens de teste	Precisão	Recall	F1
SB	2.363	0,886	**0,970**	0,926
ST	1.067	0,748	0,880	0,808
SR	1.179	0,687	0,723	0,704
SVT	99	0,552	0,697	0,616
AF	1.194	0,673	0,668	0,671
SA	272	0,644	0,173	0,273
AFIB	267	0,133	0,008	0,014
AT	37	0,000	0,000	0,000
AVRT	4	0,000	0,000	0,000



Primeiras observações

- **A acurácia de 77% esconde o desbalanceamento.** O F1 macro é 0,45: o modelo acerta bem as classes grandes (SB, ST, SR, AF) e quase nunca prevê as raras (AFIB, AT, AVRT).
- **AFIB é confundida com AF:** 189 das 267 fibrilações foram classificadas como flutter. São as duas arritmias atriais, e AF tem 4,5 vezes mais exemplos.
- **SA é confundida com SR:** 150 das 272 irregularidades sinusais foram classificadas como ritmo normal, uma diferença sutil na imagem.
- **Sem overfitting:** a loss de validação ficou abaixo da de treino em todas as épocas. Isso é esperado porque o dropout da EfficientNet só atua no treino. As curvas estabilizam já na 2ª época, o que indica **underfitting**: com o backbone congelado, só a última camada aprende.
- **Próximos passos:** aplicar os pesos por classe na loss, rodar as configurações B, C e D e comparar com este baseline.