Documentação dos modelos — classificação de ECG (PTB-XL)

Oct 19, 2026 · @pedro

Dos 15 modelos avaliados no Orange, 4 redes neurais passam no corte de AUC ⩾ 0,70 no teste de 500 ECGs; os outros 11 saem por ficarem abaixo desse corte ou por colapsarem em uma única classe.

Dados

O conjunto é um subconjunto balanceado de imagens de ECG derivado do dataset baseado no PTB-XL: 5 classes (CD, HYP, MI, NORM, STTC), com 400 imagens de treino e 100 de teste por classe, totalizando 2.500 imagens (2.000 treino, 500 teste). Com 5 classes balanceadas, um classificador aleatório acerta 20% (CA = 0,200).

O t-SNE dos 2.000 exemplos (normalização + PCA com 20 componentes, inicialização PCA, distância euclidiana, perplexidade 30) não mostra agrupamentos por classe: os pontos de CD, HYP, MI, NORM e STTC aparecem misturados em toda a nuvem. Isso indica que as classes se sobrepõem bastante no espaço de entrada e antecipa o teto baixo de desempenho visto na tabela de resultados.

Resultados no teste (500 imagens)

Métricas médias sobre as 5 classes, geradas pelo widget Predictions do Orange, ordenadas por AUC.

#	Modelo	AUC	CA	F1	Prec	Recall	MCC
1	NN · Identity · Adam · 20,20,20,20,20	0,744	0,424	0,422	0,423	0,424	0,281
2	NN · Identity · Adam · 10 × 8 camadas	0,741	0,424	0,424	0,424	0,424	0,280
3	NN · Identity · Adam · 100,100,100	0,735	0,438	0,433	0,434	0,438	0,299
4	NN · ReLU · Adam · 100,100,100	0,708	0,392	0,390	0,391	0,392	0,240
5	KNN · Manhattan · por distância · k=100	0,676	0,326	0,317	0,333	0,326	0,161
6	KNN · Euclidiana · uniforme · k=100	0,673	0,328	0,320	0,328	0,328	0,162
7	KNN · Manhattan · uniforme · k=100	0,673	0,328	0,319	0,330	0,328	0,163
8	NN · ReLU · Adam · 20 × 6 camadas	0,651	0,362	0,363	0,364	0,362	0,203
9	NN · tanh · L-BFGS-B · 400,10,400,10 (execução A)	0,649	0,334	0,330	0,332	0,334	0,168
10	NN · tanh · L-BFGS-B · 400,10,400,10 (execução B)	0,627	0,312	0,309	0,310	0,312	0,140

#	Modelo	AUC	CA	F1	Prec	Recall	MCC
11	KNN · Manhattan · por distância · k=5	0,625	0,322	0,322	0,325	0,322	0,153
12	KNN · Euclidiana · uniforme · k=5	0,620	0,304	0,298	0,300	0,304	0,131
13	KNN · Manhattan · uniforme · k=5	0,619	0,310	0,305	0,308	0,310	0,138
14	NN · Logistic · SGD · 20,100,100,20	0,488	0,200	0,067	0,040	0,200	0,000
15	NN · Logistic · SGD · 100,20,20,100	0,482	0,200	0,067	0,040	0,200	0,000

Filtro aplicado e justificativa

Regra proposta: manter apenas modelos com AUC ⩾ 0,70 e que não colapsem em uma única classe. O corte cai num intervalo natural da tabela: há um salto entre o 4º modelo (AUC 0,708) e o 5º (0,676), sem nenhum modelo no meio.

Grupo removido	Modelos (#)	Evidência	Justificativa
Colapso em classe única	NN Logistic · SGD (14, 15)	CA = 0,200, MCC = 0,000, F1 = 0,067, Prec = 0,040	Os valores coincidem com o de um modelo que prevê sempre a mesma classe: acerto igual ao acaso (20%) e MCC nulo. Não aprenderam nada útil.
KNN, todas as variações	KNN (5, 6, 7, 11, 12, 13)	AUC 0,619–0,676; CA 0,304–0,328	Métrica (Manhattan ou Euclidiana) e ponderação (uniforme ou por distância) mudam a CA em menos de 0,03 para o mesmo k, então o ajuste fino não resolve. Aumentar k de 5 para 100 ajuda (AUC +0,05), mas continua abaixo do corte. Coerente com o t-SNE: vizinhos próximos de classes diferentes.
NN tanh com L-BFGS-B	NN tanh (9, 10)	AUC 0,649 e 0,627	Abaixo do corte, e a mesma configuração rendeu resultados diferentes nas duas execuções (AUC 0,649 vs 0,627), o que indica instabilidade.

Grupo removido	Modelos (#)	Evidência	Justificativa
NN ReLU 20 × 6 camadas	NN ReLU (8)	AUC 0,651; CA 0,362	Abaixo do corte. A versão ReLU mais larga e rasa (100,100,100) teve AUC 0,708, então a rede profunda e estreita não compensa.

Modelos mantidos: os 3 NN Identity · Adam (1, 2, 3) e o NN ReLU · Adam · 100,100,100 (4).

Dentro do grupo mantido, as diferenças entre os três Identity são pequenas: AUC 0,735–0,744 e CA 0,424–0,438. Com 500 amostras, o erro padrão da acurácia é de cerca de 0,022, então essas diferenças não são estatisticamente distinguíveis. Além disso, uma rede com ativação identity equivale a um modelo linear, qualquer que seja a profundidade, o que explica resultados tão parecidos. Sugestão: manter o 100,100,100 como representante (maior CA, F1 e MCC) e o 20,20,20,20,20 (maior AUC), e usar o ReLU como referência não linear.

Limitações e pontos em aberto

- O melhor modelo acerta 43,8% das imagens, cerca de 2,2 vezes o acaso (20%). O filtro escolhe os menos fracos; o desempenho geral ainda é baixo, e o t-SNE sugere que o limite pode estar na representação dos dados e não só no classificador.
- Falta registrar como as imagens foram transformadas em atributos antes dos modelos (extração de características, tamanho da imagem, embeddings).
- Os nomes das execuções 9 e 10 são idênticos; vale anotar o que as diferencia (semente, iterações, regularização).
- A configuração do modelo 2 aparece truncada na tela (10 neurônios por camada, 8 camadas visíveis); confirmar o número exato de camadas.
- Todos os números vêm de um único conjunto de teste de 500 imagens, sem validação cruzada.